## 山东大学 计算机科学与技术 学院

## 信息检索与数据挖掘 课程实验报告

学号: 201600130032 | 姓名: 陆禹承 | 班级: 智能 16

实验题目: BM25

实验内容:

实现 BM25 模型

## 实验过程中遇到和解决的问题:

使用和上次相似的代码,主要更改的是增加 rating 功能 算法过程:

首先根据用户查询筛选出文档,然后对每个文档进行 rating (这些文档数据已经被分过词)

rating 的式子大致如下:

Pivoted Length Normalization VSM [Singhal et al 96]

$$f(q,d) = \sum_{w \in q \cap d} c(w,q) \frac{\ln[1 + \ln[1 + c(w,d)]]}{1 - b + b \frac{|d|}{avdl}} \log \frac{M + 1}{df(w)}$$

其中常数值根据多次尝试自行选择了一个合适的数值,这样排名出来的效果会好很多

此外还对运算过程进行了优化,计算速度都有大幅度的提升。多个 AND/OR 运算可以同时运算(使用一个小根堆进行排序),对于 a&b&c 这种情况效率有小幅度提升。

为了方便 rating 的计算,

做 inverted index list 时统计了词汇频率(tf),并统计所有文档长度结果出来以后,再对每个文档进行评价,最后根据得分排序。 评析时对每个查询词计算结果求和

文档处理要花费几分钟的时间,为了方便调试,将处理过的文档信息暂存下来(cache),方便之后读入使用(只需要几秒的时间)

查询花费时间较小,简单查询基本<1s

运行效果:

结论分析与体会:

对模型优化有所了解